

روش‌های یادگیری تانسوری

مهدی مولوی،

۲۳ بهمن ۱۳۹۶

استاد راهنما: دکتر منصور رزقی

فهرست

۱. مقدمه

۲. انواع تجزیه

۳. تعمیم یادگیری‌ها به ابعاد بالاتر

۴. سرعت بخشی


۵. رویکرد دیگر برای تجزیه SVD برای ابعاد بالاتر

۶. نتیجه گیری


مقدمه

چند تعریف...


تانسور




تانسور سه بعدی




(a) Mode-1 (column) fibers: $\mathbf{x}_{:jk}$




(b) Mode-2 (row) fibers: $\mathbf{x}_{i:k}$




(c) Mode-3 (tube) fibers: $\mathbf{x}_{ij:}$



(a) Horizontal slices: $\mathbf{X}_{i,:}$



(b) Lateral slices: $\mathbf{X}_{:,j}$



(c) Frontal slices: $\mathbf{X}_{::k}$ (or \mathbf{X}_k)

ترانهاده ماتریس

ترانهاده تانسور ۳- بعدی $A \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ را با A^T نشان داده که یک تانسور با ابعاد $n_1 \times n_2 \times n_3$ است.

ترانهاده ماتریس

ترانهاده تانسور ۳- بعدی $\mathcal{A} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ را با \mathcal{A}^T نشان داده که یک تانسور با ابعاد $n_1 \times n_2 \times n_3$ است.

تانسور همانی

یک تانسور سه بعدی صفر را که تنها در اسلایس اولی ماتریس همانی وجود دارد را تانسور همانی گوئیم.

ترانهاده ماتریس

ترانهاده تانسور ۳- بعدی $\mathcal{A} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ را با \mathcal{A}^T نشان داده که یک تانسور با ابعاد $n_1 \times n_2 \times n_3$ است.

تانسور همانی

یک تانسور سه بعدی صفر را که تنها در اسلایس اولی ماتریس همانی وجود دارد را تانسور همانی گوئیم.

ضرب داخلی

ضرب داخلی دو تانسور هم‌اندازه $\mathcal{X}, \mathcal{Y} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ به‌صورت زیر تعریف می‌شود.

$$\langle \mathcal{X}, \mathcal{Y} \rangle = \sum_{i_1=1}^{I_1} \cdots \sum_{i_N=1}^{I_N} x_{i_1, i_2, \dots, i_N} y_{i_1, i_2, \dots, i_N}$$

انواع تجزيه

تجزیه CP

تجزیه CP یک تانسور، مجموع اجزای رتبه یک تانسور است. به عنوان مثال؛ تانسور سه بعدی $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$ را می‌توانیم به صورت زیر تقریب بزنیم.


$$\mathcal{X} \approx \sum_{r=1}^R a_r \circ b_r \circ c_r,$$

که در آن R یک عدد مثبت و $a_r \in \mathbb{R}^I$ ، $b_r \in \mathbb{R}^J$ و $c_r \in \mathbb{R}^K$ است.

تجزیه CP یک تانسور، مجموع اجزای رتبه یک تانسور است. به عنوان مثال؛ تانسور سه بعدی $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$ را می‌توانیم به صورت زیر تقریب بزنیم.

$$\mathcal{X} \approx \sum_{r=1}^R a_r \circ b_r \circ c_r,$$

که در آن R یک عدد مثبت و $a_r \in \mathbb{R}^I$ ، $b_r \in \mathbb{R}^J$ و $c_r \in \mathbb{R}^K$ است.




فرض کنید که هدف محاسبه بهترین تقریب برای تانسور سه بعدی \mathcal{X} است.

$$\min_{\hat{\mathcal{X}}} \|\mathcal{X} - \hat{\mathcal{X}}\| \quad \text{با} \quad \hat{\mathcal{X}} = \sum_{r=1}^R \lambda_r a_r \circ b_r \circ c_r = [\lambda; A, B, C].$$

که می‌توان با ثابت فرض کردن A و B ، برای A حل کرد و همینطور به صورت تکراری برای ماتریس‌های دیگر.

HOSVD

HOSVD



تجزیه HOSVD

HOSVD

```

procedure HOSVD( $\mathcal{X}, R_1, R_2, \dots, R_N$ )
  for  $n = 1, \dots, N$  do
     $\mathbf{A}^{(n)} \leftarrow R_n$  leading left singular vectors of  $\mathbf{X}_{(n)}$ 
  end for
   $\mathcal{G} \leftarrow \mathcal{X} \times_1 \mathbf{A}^{(1)\top} \times_2 \mathbf{A}^{(2)\top} \dots \times_N \mathbf{A}^{(N)\top}$ 
  return  $\mathcal{G}, \mathbf{A}^{(1)}, \mathbf{A}^{(2)}, \dots, \mathbf{A}^{(N)}$ 
end procedure

```

HOSVD

```

procedure HOSVD( $\mathcal{X}, R_1, R_2, \dots, R_N$ )
  for  $n = 1, \dots, N$  do
     $\mathbf{A}^{(n)} \leftarrow R_n$  leading left singular vectors of  $\mathbf{X}_{(n)}$ 
  end for
   $\mathcal{G} \leftarrow \mathcal{X} \times_1 \mathbf{A}^{(1)\top} \times_2 \mathbf{A}^{(2)\top} \dots \times_N \mathbf{A}^{(N)\top}$ 
  return  $\mathcal{G}, \mathbf{A}^{(1)}, \mathbf{A}^{(2)}, \dots, \mathbf{A}^{(N)}$ 
end procedure

```

هدف محاسبه مسئله بهینه سازی زیر است:

$$\begin{aligned}
 & \min_{\mathcal{G}, \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)}} \|\mathcal{X} - [\mathcal{G}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)}]\| \\
 & s.t \quad \mathcal{G} \in \mathbb{R}^{R_1 \times \dots \times R_N}
 \end{aligned}$$

که در آن $\mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R_n}$ و متعامد است.

تعمیم یادگیری‌ها به ابعاد بالاتر

ماشین تانسور پشتیبان

تعمیم ماشین بردار پشتیبان

STM

ماشین بردار پشتیبان از بهینه‌سازی استفاده می‌کند و هدف آن پیدا کردن مرزهای جداسازی بهینه است. این مرزهای بهینه با کمینه کردن خطا میان تمام مرزهای ممکن تخمین زده شده توسط نمونه‌ها بدست می‌آید. تابع تصمیم ماشین بردار پشتیبان کلاسیک را می‌توان به صورت

$$y(a) = \text{sign}(w^T a + b)$$

نوشت. $a \in \mathbb{R}^{L \times 1}$ بردار بدون برچسب ورودی، $y \in \{-1, +1\}$ برچسب حدس زده شده و $w \in \mathbb{R}^{L \times 1}$ ماتریس تصویر است.

STM

پارامترهای این مدل را می‌توان با حل کردن بهینه‌سازی زیر بدست آورد:

$$\begin{aligned} \min_{w, b, \xi} f(w, b, \xi) &= \frac{1}{2} \|w\|^2 + c \sum_{i=1}^N \xi_i \\ \text{s.t. } y_i [w^T a_i + b] &\geq 1 - \xi_i, \quad \xi_i \geq 0, \quad 1 \leq i \leq N \end{aligned}$$

هدف اصلی ماشین تانسور پشتیبان یافتن ابرصفحاتی است که داده‌های تانسوری را با توجه به نمونه‌های آموزشی از هم جدا کند. تابع تصمیم‌گیری چندخطی برای ماشین تانسور پشتیبان، داده‌ی تانسوری بدون برچسب ورودی $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$ ، به صورت

$$y(\mathcal{A}) = \text{sgn} \left(\mathcal{A} \prod_{k=1}^N \times_k w_k + b \right)$$

تعریف می‌شود. که در آن $y \in \{+1, -1\}$ ، b است.

STM

وزن‌های w_k به صورت زیر محاسبه می‌شود:

$$\begin{aligned} \min_{w_k |_{k=1}^N} f(w_k |_{k=1}^N, b, \xi) &= \frac{1}{r} \|w_1 \circ w_2 \circ \dots \circ w_N\|^2 + c \sum_{i=1}^N \xi_i \quad (1) \\ \text{s.t. } y_i \left[\mathcal{A}_i \prod_{k=1}^N \times_k w_k + b \right] &\geq 1 - \xi_i, \quad 1 \leq i \leq M, \quad \xi_i \geq 0 \end{aligned}$$

STM

وزن‌های w_k به صورت زیر محاسبه می‌شود:

$$\begin{aligned} \min_{w_k|_{k=1}^N} f(w_k|_{k=1}^N, b, \xi) &= \frac{1}{\gamma} \|w_1 \circ w_2 \circ \dots \circ w_N\|^2 + c \sum_{i=1}^N \xi_i \quad (1) \\ \text{s.t. } y_i \left[\mathcal{A}_i \prod_{k=1}^N \times_k w_k + b \right] &\geq 1 - \xi_i, 1 \leq i \leq M, \quad \xi_i \geq 0 \end{aligned}$$

که در آن $w_k|_{k=1}^N$ بیانگر وزن در حالت k ام است. در این معادله، ξ_i بردار متغیر اسلک بوده و c ضریب منظم‌ساز برای کنترل خطاهای طبقه‌بندی است. همچنین M تعداد کل نمونه‌ها و \mathcal{A}_i نشان‌دهنده‌ی i امین تانسور داده‌های آموزشی است.

STM


می‌توان از روش‌های متناوب برای پیدا کردن جوابی مناسب استفاده کرد. گرچه این روش‌ها تضمینی برای رسیدن به نقطه‌ی کمینه به ما نمی‌دهند اما ثابت شده که همواره به یک نقطه‌ی کمینه‌ی محلی خواهند رسید. پس از محاسبه‌ی w_j و b می‌توان ابرصفحه‌ی جداساز را با استفاده از رابطه‌ی زیر محاسبه کرد:

STM

می‌توان از روش‌های متناوب برای پیدا کردن جوابی مناسب استفاده کرد. گرچه این روش‌ها تضمینی برای رسیدن به نقطه‌ی کمینه به ما نمی‌دهند اما ثابت شده که همواره به یک نقطه‌ی کمینه‌ی محلی خواهند رسید. پس از محاسبه‌ی w_j و b می‌توان ابرصفحه‌ی جداساز را با استفاده از رابطه‌ی زیر محاسبه کرد:

$$\mathcal{A} \prod_{k=1}^N \times_k w_k + b = \circ.$$

نمایی از جداسازی دودویی به وسیله‌ی ماشین تانسور پشتیبان در فضای با ابعاد بالا



Clustering Spectral Tensor

Regression Tensor Logistic

سرعت بخشی

HOSVD for Dimensionality Reduction

مقدمه

فرض کنید $M_1 \in \mathbb{R}^{m_1 \times n}$ و $M_2 \in \mathbb{R}^{m_2 \times n}$ که $m_1 < m_2$ است و $M_2 = [M_1, \circ]$.
هرگاه تجزیه SVD آن‌ها به صورت زیر باشد:

$$M_1 = U_1 \Sigma_1 V_1^T$$

$$M_2 = U_1 \Sigma_1 V_1^T$$

در این صورت ماتریس متعامد U_1 معادل با U_2 است.

مقدمه

فرض کنید $M_1 \in \mathbb{R}^{m_1 \times n}$ و $M_2 \in \mathbb{R}^{m_2 \times n}$ که $m_1 < m_2$ است و $M_2 = [M_1, \circ]$. هرگاه تجزیه SVD آن‌ها به صورت زیر باشد:

$$M_1 = U_1 \Sigma_1 V_1^T$$

$$M_2 = U_1 \Sigma_1 V_1^T$$

در این صورت ماتریس متعامد U_1 معادل با U_2 است.

نتیجه: فرض کنید $M_1 = [v_1, \dots, v_n]$ و $M_2 = [v_1, v_2, \dots, \circ, \dots, \circ, v_n]$ ، در این صورت پایه‌هی معادل دارن.

معادل بودن تانسوری هسته $HOSVD$

فرض کنید $T \in \mathbb{R}^{I_1 \times \cdots \times I_N}$ و $G \in \mathbb{R}^{I_1 \times \cdots \times (kI_n) \times \cdots \times I_N}$ باشد. با در نظر گرفتن ماتریس

$$M = \begin{pmatrix} I \\ \circ \end{pmatrix}, \quad M \in \mathbb{R}^{I_n \times (kI_n)}$$

تانسور T و G در رابطه زیر صدق می‌کند:

$$T = G \times_n M = G \times_n \begin{pmatrix} I_n \\ \circ_{kn} \end{pmatrix},$$

IHOSVD

این روش شامل سه الگوریتم است که در اولین الگوریتم، یک الگوریتم بازگشتی می‌باشد که تابع زیر را بدست می‌آورد:

$$f(M_n, C_n) = \begin{cases} \text{svd}(M_1), & n = 1 \\ \text{mix}(f(M_{n-1}, C_{n-1}), C_n), & n > 1 \end{cases}$$

IHOSVD

Algorithm 1 Recursive matrix singular value decomposition,
 $(U, \Sigma, V) = R - MSvd(M_n, C_n)$.

Input:

Initial matrix M_n .

Incremental matrix C_n .

Output:

Decomposition results U, S, V of matrix $[M_n \ C_n]$.

1: **if** $(n == 1)$ **then**

2: $[U, \Sigma, V] = svd(M_1)$.

3: **else**

4: $[U_m, \Sigma_m, V_m] = R - MSvd(M_{n-1}, C_{n-1})$.

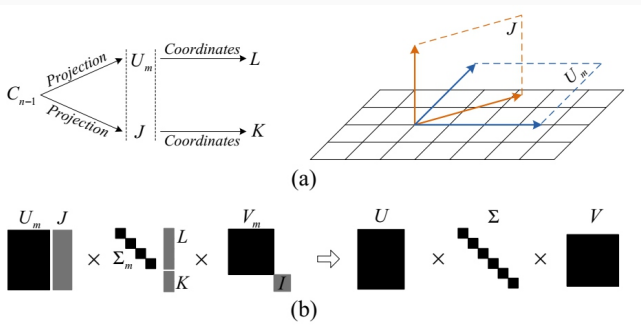
5: $[U, \Sigma, V] = mix(M_{n-1}, C_{n-1}, U_m, \Sigma_m, V_m)$.

6: **end if**

7: **return** U, S, V .

IHOSVD

دومین الگوریتم، SVD را بروزرسانی می کند. از ورودی ماتریس C_{n-1} را خوانده و به فضای متعامد تولید شده از U_m تصویر می کند.



Algorithm 2 Merge incremental matrix with decomposition results, $(U, \Sigma, V) = \text{mix}(M_{n-1}, C_{n-1}, U_m, \Sigma_m, V_m)$.

Input:

Initial matrix M_{n-1} and incremental matrix C_{n-1} .
 Decomposition results U_m, Σ_m, V_m of matrix M .

Output:

New decomposition results U, Σ, V .


- 1: Project C_{n-1} on the orthogonal space spanned by U_m ,
 $L = U_m^T \times C_{n-1}$.
 - 2: Compute H which is orthogonal to U_m , $H = C_{n-1} - U_m \times L$.
 - 3: Obtain the unitary orthogonal basis J from matrix H .
 - 4: Compute the coordinates of matrix H , $K = J^T \times H$.
 - 5: Execute SVD on the new matrix $[U \ J]$, $[U', \Sigma', V'] = \text{svd}([U \ J])$.
 - 6: Obtain new decomposition results, $([U \ J], U') \rightarrow U, \Sigma' \rightarrow \Sigma, V' \rightarrow V$.
 - 7: **return** U, S, V .
-

IHOSVD

با استفاده از سومین الگوریتم ما هسته تانسور را حساب خواهیم کرد.

IHOSVD

با استفاده از سومین الگوریتم ما هسته تانسور را حساب خواهیم کرد.



Algorithm 3 Incremental tensor singular value decomposition,
 $(S, [U, \Sigma, V]_{new}) = I - TSvd(\chi, T, [U, \Sigma, V]_{initial})$.

Input:

New tensor $\chi \in R^{I_1 \times I_2 \times \dots \times I_N}$.

Previous tensor $T \in R^{I_1 \times I_2 \times \dots \times I_N}$.

Previous unfolded matrices SVD results $[U, \Sigma, V]_{initial}$.

Output:

New truncated SVD results $[U, \Sigma, V]_{new}$.

New core tensor S .

- 1: Extend tensor χ and tensor T to identical dimensionality.
 - 2: Unfold new tensor χ to matrices $\chi_{(1)}, \dots, \chi_{(N)}$.
 - 3: Call algorithm $R - MSvd$ to update above unfolded matrices.
 - 4: Truncate the new orthogonal bases.
 - 5: Combine new tensor χ with initial tensor T .
 - 6: Obtain new core tensor S with n -mode product.
 - 7: **return** S , and $[U, \Sigma, V]_{new}$.
-

زمان پیچیدگی

زمان محاسبه برای روش ارائه شده به صورت مجموع سه الگوریتم است که به صورت زیر محاسبه می‌شود:

$$Time = Time_{unf} + Time_{isvd} + Time_{prod}.$$

که عمل تبدیل unfolding یک عمل از مرتبه $\mathcal{O}(1)$ است. زمان $Time_{isvd}$ مجموع زمان‌های مصرفی برای unfold کردن ماتریس $T_{(i)}$ است.

$$Time_N = \sum_{i=1}^N Time_i$$

$$Time(n) = \begin{cases} C_1, & n = 1 \\ Time(n-1) + C_2, & n > 1 \end{cases}$$

پس زمان کل برابر $\mathcal{O}(k^2 n)$ است.

رویکرد دیگر برای تجزیه SVD برای ابعاد
بالا تر

T-SVD

تعاریف مقدماتی

ماتریس پیچشی

تانسور سه بعدی $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ با $l \times m$ اسلایس پیشی مفروض است. در این صورت

$$\text{circ}(\mathcal{A}) = \begin{pmatrix} A^{(1)} & A^{(n)} & A^{(n-1)} & \dots & A^{(2)} \\ A^{(2)} & A^{(1)} & A^{(n)} & A^{(n-1)} & \dots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ A^{(n)} & A^{(n-1)} & \dots & A^{(2)} & A^{(1)} \end{pmatrix}$$

که ماتریس پیچشی بلوکی از سائز $ln \times mn$ است.

T-Product

عملگرهای *fold* و *MatVec*

عملگر *MatVec* تانسور سه بعدی به ابعاد $l \times m \times n$ را به ماتریس بلوکی با ابعاد $ln \times m$ برمی گرداند و عملگر *fold* معکوس این عملگر را انجام می دهد.

$$fold(MatVec(\mathcal{A})) = \mathcal{A}, \quad MatVec(\mathcal{A}) = \begin{pmatrix} A^{(1)} \\ A^{(2)} \\ \vdots \\ A^{(n)} \end{pmatrix}$$

t -ضرب

فرض کنید $A \in \mathbb{R}^{l \times p \times n}$ و $B \in \mathbb{R}^{p \times m \times n}$. در این صورت t -ضرب با ابعاد $l \times m \times n$ را به صورت $A \star B$ نشان داده و به صورت زیر تعریف می‌شود.

$$A \star B = \text{fold}(\text{circ}(A) \text{MatVec}(B)).$$

t -ضرب

فرض کنید $A \in \mathbb{R}^{l \times p \times n}$ و $B \in \mathbb{R}^{p \times m \times n}$. در این صورت t -ضرب با ابعاد $l \times m \times n$ را به صورت $A \star B$ نشان داده و به صورت زیر تعریف می‌شود.

$$A \star B = \text{fold}(\text{circ}(A) \text{MatVec}(B)).$$

این ضرب در حالت کلی خاصیت جابجایی ندارد.

t-ضرب

فرض کنید $A \in \mathbb{R}^{l \times p \times n}$ و $B \in \mathbb{R}^{p \times m \times n}$. در این صورت t -ضرب با ابعاد $l \times m \times n$ را به صورت $A \star B$ نشان داده و به صورت زیر تعریف می‌شود.

$$A \star B = \text{fold}(\text{circ}(A) \text{MatVec}(B)).$$

این ضرب در حالت کلی خاصیت جابجایی ندارد.

تبدیل فوریه گسسته (DFT)

ماتریس مربعی F با ابعاد N در N را به صورت $F = \left(\frac{w^{jk}}{\sqrt{N}} \right)_{j,k=0,\dots,N-1}$ که در آن $\omega = e^{-2\pi i/N}$ است. به صورت ماتریس داریم:

$$F = \frac{1}{\sqrt{N}} \begin{bmatrix} 1 & 1 & 1 & 1 & \dots & 1 \\ 1 & \omega & \omega^2 & \omega^3 & \dots & \omega^{N-1} \\ 1 & \omega^2 & \omega^4 & \omega^6 & \dots & \omega^{2(N-1)} \\ 1 & \omega^3 & \omega^6 & \omega^9 & \dots & \omega^{3(N-1)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{N-1} & \omega^{2(N-1)} & \omega^{3(N-1)} & \dots & \omega^{(N-1)(N-1)} \end{bmatrix},$$

T-SVD

هرگاه F ماتریس نرمال شده تبدیل فوریه باشد، برای $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ ،
ماتریس با درآیه‌های مختلط $\hat{A}^{(i)}$ با ابعاد $l \times m$ وجود دارد به طوریکه:

$$(F \otimes I) \text{circ}(\mathcal{A}) (F^* \otimes I) = \begin{pmatrix} \hat{A}^{(1)} & \circ & \dots & \circ \\ \circ & \hat{A}^{(2)} & \dots & \circ \\ \vdots & \ddots & \ddots & \vdots \\ \circ & \circ & \dots & \hat{A}^{(n)} \end{pmatrix} = \hat{\mathcal{A}},$$

اما نیاز نیست که به صورت صریح $\hat{\mathcal{A}}$ از $\text{circ}(\mathcal{A})$ تولید شود. با تبدیل فوریه از مد سوم تانسور \mathcal{A} تانسور $\hat{\mathcal{A}}$ ، تولید می‌شود.

T-SVD

هرگاه F ماتریس نرمال شده تبدیل فوریه باشد، برای $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ ،
ماتریس با درآیه‌های مختلط $\hat{A}^{(i)}$ با ابعاد $l \times m$ وجود دارد به طوریکه:

$$(F \otimes I) \text{circ}(\mathcal{A}) (F^* \otimes I) = \begin{pmatrix} \hat{A}^{(1)} & \circ & \dots & \circ \\ \circ & \hat{A}^{(2)} & \dots & \circ \\ \vdots & \ddots & \ddots & \vdots \\ \circ & \circ & \dots & \hat{A}^{(n)} \end{pmatrix} = \hat{\mathcal{A}},$$

اما نیاز نیست که به صورت صریح $\hat{\mathcal{A}}$ از $\text{circ}(\mathcal{A})$ تولید شود. با تبدیل فوریه از مد سوم تانسور \mathcal{A} تانسور $\hat{\mathcal{A}}$ ، تولید می‌شود.

توجه: برای تانسور \mathcal{A} و \mathcal{B} داریم:

$$\mathcal{A} \star \mathcal{B} = \mathcal{C} \iff \hat{\mathcal{A}} \hat{\mathcal{B}} = \hat{\mathcal{C}}$$

T-SVD and T-QR

تجزیه $T - QR$

با استفاده از تعریف فوق می‌توان تانسور A را بصورت $A = Q * R$ نوشت که در آن Q معکوس تبدیل فوریه \hat{Q} مد ۳ است.

T-SVD and T-QR

تجزیه $T-QR$

با استفاده از تعریف فوق می‌توان تانسور A را بصورت $A = Q * R$ نوشت که در آن Q معکوس تبدیل فوریه \hat{Q} مد ۳ است.

تجزیه $T-SVD$


با استفاده از تعریف می‌توان تانسور A را بصورت $A = U * S * V^T$ نوشت.

T_SVD

تجزیه $t - SVD$ که در آن S تانسور قطری است به فرم زیر نشان داده می‌شود.

T_SVD

تجزیه t -SVD که در آن S تانسور قطری است به فرم زیر نشان داده می‌شود.



الگوریتم t -SVD برای تانسور سه بعدی به صورت زیر است:

Algorithm 1 t -SVD for third order tensors

Input: $\mathcal{M} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$.

Output: $\mathcal{U} \in \mathbb{R}^{n_1 \times n_1 \times n_3}$, $\mathcal{S} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$, $\mathcal{V} \in \mathbb{R}^{n_2 \times n_2 \times n_3}$.

$\mathcal{D} \leftarrow \text{fft}(\mathcal{M}, [], 3)$

for $i = 1$ **to** n_3 **do**

$[\mathbf{U}, \mathbf{S}, \mathbf{V}] = \text{svd}(\mathcal{D}^{(i)})$

$\hat{\mathcal{U}}^{(i)} = \mathbf{U}$; $\hat{\mathcal{S}}^{(i)} = \mathbf{S}$; $\hat{\mathcal{V}}^{(i)} = \mathbf{V}$;

end for

$\mathcal{U} \leftarrow \text{ifft}(\hat{\mathcal{U}}, [], 3)$; $\mathcal{S} \leftarrow \text{ifft}(\hat{\mathcal{S}}, [], 3)$; $\mathcal{V} \leftarrow \text{ifft}(\hat{\mathcal{V}}, [], 3)$

۱ تعریف معین مثبت.

- ۱ تعریف معین مثبت.
- ۲ تانسور متعامد

۱ تعریف معین مثبت.


۲ تانسور متعامد

۳ *squeenz*

۱ تعریف معین مثبت.

۲ تانسور متعامد

۳ *squeenz*



ضرب داخلی

۴ ضرب داخلی برای $\langle x, y \rangle := x^T \star y$

ضرب داخلی

۴ ضرب داخلی برای $\langle x, y \rangle := x^T \star y$

1. $\langle \vec{x}, \vec{y} + \vec{z} \rangle = \langle \vec{x}, \vec{y} \rangle + \langle \vec{x}, \vec{z} \rangle$
2. $\langle \vec{x}, \vec{y} * \mathbf{a} \rangle = (\vec{x}^T * \vec{y}) * \mathbf{a} = \mathbf{a} * (\vec{x}^T * \vec{y}) = \mathbf{a} * \langle \vec{x}, \vec{y} \rangle$
3. $\langle \vec{x}, \vec{y} \rangle = \langle \vec{y}, \vec{x} \rangle^T$

کاربرد $TSVD$

$$\begin{aligned} \min_{\mathcal{X}} \quad & \|\mathcal{X}\|_{TNN} \\ \text{subject to} \quad & \mathcal{X}_{ijk} = \mathcal{M}_{ijk}, (i, j, k) \in \Omega \end{aligned}$$

نتیجه گیری

...



سوال؟